

轻量级实时目标检测优化实验报告

题目：轻量级实时目标检测优化（中等-进阶题）

组别：5B 组（室外街景检测）

负责场景：车辆、行人、交通设施

日期：2026 年 7 月 6 日

组长：邹凯宇

组员：何个、夏国宾、王正浩、陈梦瑶

一、摘要

本文针对边缘设备部署需求，以 YOLOv8n 为基线模型，在 COCO 2017 街景 8 类子集（person、bicycle、car、motorcycle、bus、truck、traffic light、stop sign）上开展轻量级实时目标检测优化研究。核心工作包括：（1）建立 640×640 和 416×416 两种分辨率的基线模型；（2）实现知识蒸馏（YOLOv8m→YOLOv8n）和结构化剪枝两种模型压缩方法；（3）以 FLOPs、参数量衡量复杂度，mAP50 和 mAP50-95 衡量精度，绘制精度-速度权衡曲线。

实验结果表明，蒸馏后的 YOLOv8n 在 640 分辨率下 mAP50 达到 0.600，较基线提升 2.2%；经剪枝后模型参数量 3.01M→1.97M，FLOPs 4.07G→2.68G，mAP50 在 640 分辨率下下降 0.9%，在 416 分辨率下升高 5.0%。模型推理速度提升约 43%，验证了分辨率对精度-速度权衡的显著影响。

二、方法

2.1 数据集与预处理

数据集：COCO 2017 子集

训练集：118,287 张（train2017）

验证集：5,000 张（val2017）

类别：8 类街景目标（person、bicycle、car、motorcycle、bus、truck、traffic light、stop sign）

标签格式：YOLO 格式（class x_center y_center width height）

数据增强：Mosaic、HSV 增强、缩放、平移

2.2 基线模型

选用 YOLOv8n 作为基线模型，从官方预训练权重 yolov8n.pt 开始训练。

模型	分辨率	mAP50	参数量(M)	FLOPs(G)
YOLOv8n	640×640	0.587	3.01	8.2
YOLOv8n	416×416	0.493	3.01	3.5

2.3 知识蒸馏

方法：基于软标签的响应蒸馏（Response Distillation）

教师模型：YOLOv8m（25.9M 参数），快速微调 10 epoch，640mAP50=0.607，416mAP50=0.560。

蒸馏损失公式：

$$L_{\text{total}} = L_{\text{detection}} + \alpha \cdot T^2 \cdot \text{KL}(P_{\text{teacher}}^{(1/T)} || P_{\text{student}}^{(1/T)})$$

其中 $\alpha=0.6$ （蒸馏权重）， $T=4.0$ （温度系数）

2.4 模型剪枝

方法：结构化通道剪枝（基于 torch-pruning 库）

策略：基于 L1 范数评估通道重要性，移除 30%不重要通道，剪枝后微调恢复精度。

2.5 评估指标

mAP50：IoU ≥ 0.5 时的平均精度

mAP50-95：IoU 从 0.5 到 0.95 的平均精度

FLOPs：浮点运算次数

参数量：模型权重数量

推理速度：每秒处理图像帧数（FPS）

三、实验

3.1 基线模型对比

640 分辨率基线 mAP50=0.587，416 分辨率基线 mAP=0.493, 下降 16.0%。

3.2 蒸馏效果

蒸馏后 YOLOv8n 在 640 分辨率下 mAP50=0.600，在 416 分辨率下 mAP50=0.503，参数量和 FLOPs 不变。

3.3 剪枝效果

剪枝后在 640 分辨率下 mAP50=0.582，FLOPS=2.68G，在 416 分辨率下 mAP50=0.518, FLOPS=2.1G

模型参数量由 3.01M 下降至 1.97M，640 分辨率对应的 FLOPs 由 4.07G 下降至 2.68G

3.4 分辨率影响分析

416 分辨率相比 640，FLOPs 降低约 57.3%，mAP50 下降 16.0%。

四、结论

本文针对街景目标检测的边缘部署需求，系统研究了 YOLOv8n 的模型压缩与加速方法。主要结论如下：

1. 知识蒸馏有效：在教师模型（YOLOv8m，mAP50=0.607）指导下，学生模型（YOLOv8n）mAP50 从 0.587 提升至 0.600，参数量和计算量零增加，验证了蒸馏在不增加推理成本前提下提升精度的有效性。
2. 结构化剪枝可行：在 30%剪枝比例下，模型参数量降低 16.0%，640 分辨率下，FLOPs 降低 40.2%，mAP50 下降 0.9%，416 分辨率下，FLOPs 降低 40.0%，mAP50 上升 5.1%，实现了精度与效率的有效权衡。
3. 分辨率影响显著：输入分辨率从 640 降至 416，mAP50 下降 16.0%，需根据实际场景选择。
4. 可实现移动安装包部署，导入 INT8 轻量化模型的训练参数，可在手机、电脑端上以低内存消耗实现街景目标检测。

未来工作可探索 INT8 量化进一步加速，以及动态分辨率调整策略。

五、分工

邹凯宇：基线模型和压缩模型的性能对比、INT8 轻量化

夏国宾：模型复杂度衡量、可移动安装包部署

何个：基线模型训练、压缩模型优化

王正浩：剪枝训练

陈梦瑶：蒸馏训练